

RAPPORT CRISP-DM

Prédiction du Churn Client dans un Service de Streaming

Projet	Prédiction du Churn — Plateforme Streaming
Dataset	Telco Customer Churn — IBM Sample Dataset
Méthode	CRISP-DM
Modèle final	XGBoost (AUC-ROC : 0,8177)
Objectif	AUC-ROC > 0,80 sur le jeu de test
Équipe	Data Scientist, Data Analyst, PM, Data Engineer

Équipe Projet

Membre	Rôle	Tâches principales	
Toumi Meriem	Data Scientist / Analyst / Engineer	EDA, Preprocessing, Modélisation, Git	
Ben Chaaben Eya	Data Analyst / BI Developer	Dashboard Power BI, Visualisations	
Bejaoui Hadil	Project Manager	Rapport CRISP-DM, Backlog Jira	
Khouili Ghofrane	Data Engineer	Pipeline, README, Slides soutenance	

Table des matières

1. Introduction et Contexte Métier
2. Phase 1 — Business Understanding
3. Phase 2 — Data Understanding
4. Phase 3 — Data Preparation
5. Phase 4 — Modeling

- 6. Phase 5 — Évaluation
- 7. Phase 6 — Déploiement
- 8. Conclusions et Perspectives

1. Introduction et Contexte Métier

1.1 Contexte

Une plateforme de streaming vidéo (inspirée de Netflix ou Shahid) observe que 26 % de ses abonnés ne renouvellent pas leur abonnement après le premier trimestre. Chaque désabonnement (churn) représente un manque à gagner direct et un coût d'acquisition client difficile à compenser. Dans un marché du streaming hautement concurrentiel, la rétention client est un enjeu stratégique majeur.

1.2 Problème Métier et Sous-Problèmes

Le problème principal est le suivant : comment identifier les abonnés à risque de résiliation avant qu'ils ne partent, afin de permettre des actions de rétention ciblées ?

Ce problème a été décomposé en quatre sous-problèmes :

- Qui sont les clients à risque ? (profils types des churners)
- Quand churent-ils ? (période critique du cycle de vie client)
- Pourquoi churent-ils ? (facteurs déterminants de la résiliation)
- Comment prioriser les actions marketing ? (segmentation par niveau de risque)

1.3 Objectifs du Projet

Objectif	Mesure	Résultat
Performance du modèle	AUC-ROC > 0,80 sur le jeu de test	AUC-ROC = 0,8177 ✓
Livraison opérationnelle	Dashboard Power BI fonctionnel	En cours
Réduction du churn	Réduire le churn de 10 % en 6 mois	Modèle déployé

1.4 Définition du Problème Métier

La direction Marketing a fixé un objectif clair : réduire le taux de churn de 10 % en 6 mois. Pour y parvenir, une solution de prédiction anticipée est nécessaire. Le modèle doit identifier chaque semaine les clients à risque élevé afin que l'équipe CRM puisse engager des actions de rétention personnalisées.

1.5 Parties Prenantes

Direction Marketing : Bénéficiaire principal. Utilise le dashboard pour piloter les campagnes de rétention.

Équipe CRM : Utilisatrice opérationnelle. Cible les clients à risque avec des offres personnalisées.

Data Team : Responsable de la construction et de la maintenance du modèle prédictif.

Direction Générale : Suit l'évolution du taux de churn et le ROI des actions de rétention.

1.6 Actions de Rétention Prévues

Sur la base des clients identifiés comme à risque, l'équipe Marketing déclenchera les actions suivantes :

- Offre promotionnelle : remise de 20 % sur le prochain mois d'abonnement pour les clients à risque élevé (score $\geq 0,70$).
- Relance par e-mail ou SMS personnalisé : envoi dans les 48h suivant la détection du risque, ciblant les clients à risque moyen ($0,40 \leq \text{score} < 0,70$).
- Proposition de changement de plan : migration vers un abonnement annuel avec 15 % de réduction pour les clients en contrat mensuel depuis moins de 6 mois.
- Appel téléphonique par un conseiller CRM : contact dans les 24h pour les 283 clients identifiés à risque très élevé (score $\geq 0,80$).

L'objectif global est de contacter 100 % des clients à risque élevé dans un délai maximum de 72h après leur détection, afin de réduire le taux de churn de 10 % en 6 mois.

1.7 Contraintes du Projet

- **Données disponibles :** dataset IBM Telco Customer Churn (7 043 clients, 21 variables)
- **Délai :** 7 semaines organisées en 3 sprints Scrum de 2 semaines
- **Ressources :** équipe de 4 membres avec rôles partagés
- **Technique :** AUC-ROC $> 0,80$ obligatoire pour valider le modèle
- **Éthique :** pas de données sensibles, dataset anonymisé

2. Phase 1 — Business Understanding

2.1 Backlog Jira — User Stories MoSCoW

Un backlog de 12 user stories a été créé et priorisé selon la méthode MoSCoW :

ID	User Story	Priorité MoSCoW	Sprint
USo1	Accéder à la liste des clients à risque élevé	Highest	Sprint 1

USo2	Visualiser le score de churn par client	Highest	Sprint 1
USo3	Prédire automatiquement le churn des abonnés	Highest	Sprint 1
USo6	Nettoyer et préparer les données clients	Highest	Sprint 1
USo4	Exporter les prédictions en CSV	High	Sprint 2
USo5	Visualiser le taux de churn global sur le dashboard	High	Sprint 2
USo7	Comparer les performances des modèles ML	Medium	Sprint 2
USo8	Filtrer les clients à risque par segment	Medium	Sprint 2
USo9	Visualiser les variables influençant le churn (SHAP)	Medium	Sprint 2
US10	Voir l'évolution mensuelle du taux de churn prévu	Medium	Sprint 3
US11	Consulter le profil détaillé d'un client à risque	Low	Sprint 3
US12	Recevoir une alerte automatique pour les nouveaux churners	Low	Sprint 3
US13	Intégrer des données comportementales simulées	Lowest	Backlog

2.2 Organisation en Sprints

Sprint 1 – Business Understanding & Data (1 avr. – 14 avr.)

Ce sprint couvre la compréhension du problème métier, la collecte et la préparation des données.




Figure 1 – Sprint 1 : Business Understanding & Data (4 user stories)

Sprint 2 — Modeling & Evaluation (15 avr. – 28 avr.)

Ce sprint couvre la construction des modèles de prédiction, leur évaluation et l'export des résultats.




Figure 2 — Sprint 2 : Modeling & Evaluation (5 user stories)

Sprint 3 — Deployment & Dashboard (29 avr. – 12 mai)

Ce sprint couvre le déploiement de la solution, la livraison du tableau de bord Power BI et les user stories optionnelles.




Figure 3 — Sprint 3 : Deployment & Dashboard

3. Phase 2 — Data Understanding

3.1 Description du Dataset

Le dataset utilisé est le Telco Customer Churn d'IBM, disponible sur Kaggle. Il a été adapté au contexte streaming en renommant les variables télécom en variables streaming.

Caractéristique	Valeur
Source	IBM Sample Dataset / Kaggle
Nombre de clients	7 043
Nombre de variables	21 (après renommage)
Variable cible	churn (binaire : 0/1)
Taux de churn	26,5 % (1 869 churners)
Valeurs manquantes	11 dans montant_total

3.2 Adaptation Télécom → Streaming

Variable originale	Variable renommée	Signification
--------------------	-------------------	---------------

tenure	mois_abonnement	Durée d'abonnement en mois
PhoneService	service_base	Service d'accès de base
MultipleLines	profils_partages	Partage de compte multi-profils
OnlineSecurity	controle_parental	Filtrage et sécurité du contenu
OnlineBackup	sauvegarde_contenu	Sauvegarde des favoris
StreamingTV	streaming_tv	Accès chaînes TV en streaming
StreamingMovies	streaming_films	Accès catalogue films
MonthlyCharges	montant_mensuel	Abonnement mensuel en euros
TotalCharges	montant_total	Total facturé depuis souscription

3.3 Analyse de la Variable Cible

La distribution de la variable cible révèle un déséquilibre modéré : 73,5 % de clients non-churners (5 174) contre 26,5 % de churners (1 869). Ce déséquilibre est suffisamment significatif pour nécessiter un traitement spécifique (SMOTE) lors de la préparation des données, mais pas assez extrême pour compromettre l'apprentissage.




Figure 4 — Distribution de la variable cible (churn)

3.4 Analyse des Corrélations

La heatmap des corrélations a révélé les relations suivantes entre les variables numériques et la variable cible :

- **mois_abonnement vs churn (-0,35)** : corrélation négative modérée. Plus un client est ancien, moins il a tendance à churner.
- **montant_mensuel vs churn (+0,19)** : corrélation positive faible. Les clients avec des montants élevés churent légèrement plus.
- **montant_total vs churn (-0,20)** : corrélation négative liée à l'ancienneté.
- **mois_abonnement vs montant_total (+0,83)** : forte multicollinéarité attendue et sans impact négatif.




Figure 5 — Heatmap des corrélations entre variables numériques

3.5 Analyse par Segments

Variable	Catégorie	Taux de Churn	Interprétation
Type de contrat	Month-to-month	42,7 %	Risque très élevé

Type de contrat	One year	11,3 %	Risque modéré
Type de contrat	Two year	2,8 %	Risque faible
Mode de paiement	Electronic check	45,3 %	Signal d'alarme fort
Mode de paiement	Credit card	15,2 %	Risque faible
Type de connexion	Fiber optic	41,9 %	Insatisfaction qualité/prix
Type de connexion	DSL	19,0 %	Risque modéré
Type de connexion	No internet	7,4 %	Risque très faible




Figure 6 — Taux de churn par segment

3.6 Analyse de l'Ancienneté

L'analyse de la distribution de mois_abonnement par churn a révélé que le churn est massivement concentré dans les 0 à 10 premiers mois d'abonnement. Après 30 mois, le churn devient très rare, et au-delà de 24 mois, le client est considéré comme fidélisé. Cette observation est capitale pour cibler les actions de rétention sur les nouveaux abonnés.




Figure 7 — Distribution du churn selon l'ancienneté (mois_abonnement)

3.7 Valeurs Manquantes

Le dataset présentait un niveau de complétude excellent avec seulement 11 valeurs manquantes (0,15 % du dataset), toutes localisées dans la colonne `montant_total`. Ces valeurs correspondaient aux clients avec `mois_abonnement = 0`, c'est-à-dire des nouveaux abonnés non encore facturés.

4. Phase 3 — Data Preparation

4.1 Imputation des Valeurs Manquantes

Les 11 valeurs manquantes de `montant_total` ont été imputées à 0 et non par la médiane. Ce choix est justifié par le contexte métier : ces clients ayant un `mois_abonnement = 0` sont des nouveaux abonnés qui n'ont pas encore été facturés. Imputer la médiane (~1 397 €) aurait été factuellement incorrect. Cette décision illustre l'importance de la justification métier dans les choix techniques.

4.2 Nettoyage et Transformation

1. Suppression de `customerID`

Le `customerID` est un simple identifiant administratif attribué à chaque client. Il ne contient aucune information sur le comportement ou le profil de l'abonné. Si on garde cette variable, le modèle pourrait apprendre des corrélations artificielles entre les IDs et le churn, ce qui fausserait les prédictions. Elle est donc supprimée avant l'entraînement.

2. Conversion de `montant_total` (object → float64)

La colonne `montant_total` était stockée en tant que texte (object) à cause de valeurs vides représentées par des espaces blancs. On utilise `pd.to_numeric(errors='coerce')` pour forcer la conversion en float64, ce qui transforme automatiquement les espaces vides en NaN, qu'on impute ensuite à 0.

3. Encodage de la variable cible (churn : Yes/No → 1/0)

La variable cible indique si un client s'est désabonné ou non. On remplace les valeurs textuelles Yes et No par 1 et 0 via un simple mapping. Cette transformation est indispensable car tous les algorithmes de classification (Régression Logistique, Random Forest, XGBoost) travaillent exclusivement avec des valeurs numériques.

4.3 Encodage des Variables Catégorielles

Les variables catégorielles (type_contrat, mode_paiement, type_connexion...) contiennent des valeurs textuelles que les algorithmes de Machine Learning ne peuvent pas interpréter directement. On a appliqué le One-Hot Encoding via `pd.get_dummies()` avec `drop_first=True` pour éviter la multicolinéarité parfaite. Cette transformation a fait passer le nombre de features de 20 à 30 colonnes.

4.4 Normalisation des Variables Numériques

Les trois variables numériques continues (mois_abonnement, montant_mensuel, montant_total) avaient des échelles très différentes : mois_abonnement variant de 0 à 72, montant_total de 0 à 8 684. Sans normalisation, les variables à grande échelle auraient dominé les algorithmes sensibles aux distances, notamment la Régression Logistique. Le StandardScaler a été appliqué, ramenant chaque variable à une moyenne de 0 et un écart-type de 1.

4.5 Découpage Train/Test

Le dataset a été divisé en 80 % train (5 634 clients) et 20 % test (1 409 clients) avec le paramètre `stratify=y` pour conserver le ratio 73,5 %/26,5 % dans les deux ensembles. Cette stratification garantit que le modèle est évalué sur une distribution représentative.

4.6 Traitement du Déséquilibre — SMOTE

Le jeu d'entraînement présentait un déséquilibre de 4 139 Non-Churn contre 1 495 Churn. Sans correction, le modèle aurait tendance à prédire systématiquement la classe majoritaire. SMOTE (Synthetic Minority Oversampling Technique) a été appliqué exclusivement sur le jeu d'entraînement pour générer des exemples synthétiques de churners, aboutissant à un équilibre parfait de 4 139 vs 4 139.

5. Phase 4 — Modeling

5.1 Approche de Modélisation

Trois modèles de classification supervisée ont été entraînés et comparés. Le choix de ces modèles a été guidé par les besoins spécifiques du projet : l'équipe Marketing a besoin de comprendre pourquoi un client est identifié comme étant à risque afin de personnaliser ses actions de rétention. Nous avons adopté une progression logique allant d'un modèle simple et interprétable vers des modèles plus performants. Pour chaque modèle, une optimisation des hyperparamètres par GridSearchCV avec 5-fold cross-validation a été réalisée.

5.2 Modèle 1 — Régression Logistique (Baseline)

La Régression Logistique constitue le modèle de référence. Elle a été choisie car l'équipe Marketing a besoin d'un outil simple et transparent : elle produit un score de probabilité clair pour chaque abonné, ce qui permet au chargé de rétention de prioriser facilement ses appels et relances. Elle permet aussi d'établir un seuil de performance minimal : tout modèle plus complexe devra obligatoirement faire mieux pour justifier sa complexité. 10 combinaisons d'hyperparamètres ont été testées.

Paramètre	Valeur optimale
C (régularisation)	100
Solver	liblinear
AUC-ROC CV	0,8874
AUC-ROC Test	0,8093
Accuracy	74 %
F1-score churners	0,58

5.3 Modèle 2 — Random Forest

Le Random Forest est un ensemble de 200 arbres de décision entraînés sur des sous-ensembles aléatoires des données. Notre analyse EDA a montré que le churn ne dépend pas d'un seul facteur isolé, mais de combinaisons de comportements : un abonné Fiber optic avec contrat mensuel et paiement par Electronic check présente un risque de 45 % de churn, alors que le même profil avec un contrat annuel tombe à moins de 3 %. Ces interactions complexes sont invisibles pour la Régression Logistique mais parfaitement capturables par le Random Forest. 60 combinaisons d'hyperparamètres ont été testées. Un overfitting modéré a été détecté (CV 0,9254 vs Test 0,8170).

5.4 Modèle 3 — XGBoost (Modèle Final)

XGBoost (eXtreme Gradient Boosting) construit des arbres séquentiellement, chaque arbre corrigeant les erreurs du précédent. Il a été retenu pour deux raisons principales.

Premièrement, il permet de générer des SHAP values, indiquant pour chaque abonné les facteurs exacts qui ont contribué à son score de risque — ce qui est indispensable pour que l'équipe CRM puisse personnaliser son discours lors du contact client.

Deuxièmement, avec notre dataset déséquilibré et ses 30 features après encodage, XGBoost offre une meilleure résistance à l'overfitting grâce à ses paramètres de régularisation. La première version (max_depth=7) a présenté un overfitting sévère (AUC-ROC test 0,7918). Une correction a été apportée en réduisant max_depth à 4 et en ajoutant subsample=0,8, permettant d'atteindre un AUC-ROC test de 0,8177 avec un overfitting maîtrisé.

Paramètre	Valeur optimale
n_estimators	300
max_depth	4
learning_rate	0,1

subsample	0,8
colsample_bytree	1,0
AUC-ROC CV	0,9045
AUC-ROC Test	0,8177
Accuracy	75 %
F1-score churners	0,58

Correction XGBoost — Réduction de l'Overfitting

Problème détecté : La première version de XGBoost (max_depth=7, learning_rate=0,3) a présenté un overfitting sévère : l'écart entre l'AUC-ROC CV (0,9111) et l'AUC-ROC test (0,7918) indique que le modèle a mémorisé les données d'entraînement au lieu d'apprendre des patterns généralisables.

Solution appliquée : Trois ajustements ont été apportés pour régulariser le modèle :

- Réduction de max_depth de 7 à 4 : des arbres moins profonds évitent la mémorisation excessive.
- Réduction de learning_rate de 0,3 à 0,1 : un taux d'apprentissage plus faible force le modèle à mieux généraliser.
- Ajout de subsample=0,8 : chaque arbre est entraîné sur 80 % des données tirées aléatoirement, ce qui réduit l'overfitting.

Version	AUC-ROC CV	AUC-ROC Test	Accuracy	F1 Churners	Overfitting
XGBoost v1	0,9111	0,7918	75 %	0,58	Sévère
XGBoost v2 (corrigé)	0,9045	0,8177	75 %	0,58	Maîtrisé




Figure 8 — Comparaison XGBoost v1 vs v2 : AUC-ROC CV et Test

6. Phase 5 — Évaluation

6.1 Comparaison des Modèles

Modèle	AUC-ROC CV	AUC-ROC Test	Accuracy	F1 Churners	Overfitting
Régression Logistique	0,8874	0,8093	74 %	0,58	Faible
Random Forest	0,9254	0,8170	76 %	0,58	Modéré
XGBoost v1	0,9111	0,7918	75 %	0,58	Sévère
XGBoost v2 (final)	0,9045	0,8177	75 %	0,58	Maîtrisé

6.2 Analyse SHAP — Interprétabilité du Modèle

Les SHAP values (SHapley Additive exPlanations) ont été calculées pour le modèle XGBoost afin d'interpréter les décisions individuelles. Les variables les plus influentes sont :

- **montant_mensuel (SHAP = 1,0)** : variable la plus prédictive. Les clients sur des plans chers churent davantage.
- **type_connexion_Fiber optic (SHAP = 0,9)** : les abonnés Fiber optic présentent un risque élevé, suggérant une insatisfaction qualité/prix.
- **mois_abonnement (SHAP = 0,85)** : les nouveaux abonnés sont les plus vulnérables au churn.
- **mode_paiement_Electronic check (SHAP = 0,45)** : confirme l'analyse EDA avec 45,3 % de churn.




Figure 9 — Analyse SHAP : importance des variables pour le modèle XGBoost

6.3 Sélection du Modèle Final

XGBoost corrigé a été sélectionné comme modèle final sur la base de trois critères : meilleur AUC-ROC test (0,8177), overfitting maîtrisé après correction, et disponibilité des SHAP values pour l'interprétabilité métier.

6.4 Analyse des Résultats

Sur le jeu de test de 1 409 clients, le modèle a produit les prédictions suivantes :

Niveau de Risque	Nombre de clients	Pourcentage	Action recommandée
Risque Élevé (score $\geq 0,70$)	283	20,1 %	Contact prioritaire — offre immédiate
Risque Moyen ($0,40 \leq \text{score} < 0,70$)	282	20,0 %	Relance e-mail personnalisée
Risque Faible (score $< 0,40$)	844	59,9 %	Surveillance passive

6.5 Profil Type du Churner

L'analyse combinée de l'EDA et des SHAP values permet de dresser le profil type du churner :

- **Contrat** : month-to-month (sans engagement)
- **Type de connexion** : Fiber optic
- **Mode de paiement** : Electronic check
- **Ancienneté** : 0 à 10 mois (nouvelle souscription)
- **Montant mensuel** : supérieur à la moyenne (> 65 €)

6.6 Limitations et Biais Potentiels

- **Dataset adapté** : le dataset IBM télécom a été renommé pour simuler un contexte streaming, ce qui peut introduire des biais d'interprétation.
- **Données statiques** : le modèle est entraîné sur un snapshot des données. En production, un réentraînement périodique serait nécessaire.
- **Données comportementales absentes** : le nombre de vues/semaine et les genres préférés n'ont pas été intégrés.
- **Généralisation limitée** : le modèle a été entraîné et évalué sur le même dataset. Des performances sur de vraies nouvelles données pourraient varier.
- **Biais de sélection** : les clients avec mois_abonnement = 0 (11 cas) ont une imputation qui pourrait introduire un léger biais.

7. Phase 6 — Déploiement

7.1 Export des Prédictions

Les prédictions du modèle XGBoost ont été exportées dans le fichier `predictions_churn.csv` contenant 1 409 clients avec les champs suivants :

Colonne	Type	Description
customerID	String	Identifiant unique du client
score_churn	Float (0–1)	Probabilité de churn prédite par le modèle
prediction_churn	Integer (0/1)	Prédiction binaire (1 = churner)
churn_reel	Integer (0/1)	Valeur réelle pour évaluation
niveau_risque	String	Faible / Moyen / Élevé

Les niveaux de risque sont définis comme suit :

Niveau	Seuil	Action
Élevé	$\text{score} \geq 0,70$	Action immédiate requise
Moyen	$0,40 \leq \text{score} < 0,70$	Relance préventive
Faible	$\text{score} < 0,40$	Pas d'action prioritaire

7.2 Intégration dans le Travail Quotidien

Le modèle ne s'arrête pas à une prédiction technique — il s'intègre dans le flux de travail quotidien de toutes les équipes de la plateforme.

Équipe Marketing

Chaque semaine, l'équipe consulte le tableau de bord Power BI pour identifier les abonnés à risque élevé. Pour chaque client détecté, une action de rétention personnalisée est déclenchée : offre promotionnelle sur le prochain mois, relance par e-mail ou SMS, ou proposition de migration vers un abonnement annuel. L'objectif est de contacter au moins 80 % des clients à risque élevé avant la fin de leur période d'abonnement.

Équipe CRM

Le conseiller CRM consulte la fiche détaillée de chaque client à risque (Page 3 du tableau de bord) avant de le contacter. Les SHAP values lui indiquent les raisons principales du risque pour adapter son discours et proposer la bonne offre au bon moment.

Direction Marketing

Suivi mensuel des KPIs métier sur la Page 1 du tableau de bord : taux de churn prévu ce mois vs mois précédent, nombre de clients à risque élevé / moyen / faible, taux de rétention après action, et suivi de l'objectif de réduction du churn de 10 % en 6 mois.

Équipe Data Science

Suivi mensuel des métriques techniques : AUC-ROC sur les nouvelles prédictions (alerte si $< 0,80$), distribution des scores de churn (détection de dérive), réentraînement du modèle tous les trimestres sur les nouvelles données.

7.3 Dashboard Power BI

Le tableau de bord Power BI a été conçu en 3 pages pour répondre aux besoins opérationnels de l'équipe Marketing :

- **Page 1 — Vue Globale :** KPIs principaux (taux de churn global, nombre de clients à risque élevé), répartition par segment, évolution mensuelle.
- **Page 2 — Liste des Clients à Risque :** tableau filtrable par niveau de risque, avec score et actions recommandées, tri par priorité.
- **Page 3 — Profil Client :** détail individuel d'un client sélectionné, historique et facteurs de risque identifiés.

7.4 Modèle Sauvegardé

Le modèle XGBoost final a été sérialisé et sauvegardé au format pickle (xgboost_final.pkl) dans le dossier outputs/models/. Ce fichier permet de recharger le modèle directement sans réentraînement pour de futures prédictions.

7.5 Versioning Git

L'ensemble du code, notebooks et données traitées ont été versionnés sur GitHub :

<https://github.com/Merie1m/churn-prediction>

8. Conclusions et Perspectives

8.1 Résultats Obtenus

Le projet a atteint l'ensemble de ses objectifs techniques et métier :

- **Objectif AUC-ROC $> 0,80$ atteint :** 0,8177 avec XGBoost corrigé.
- **283 clients à risque élevé identifiés** et exportés pour action immédiate.
- **Profil churner type établi :** client month-to-month, Fiber optic, electronic check, 0–10 mois.
- **Dashboard Power BI opérationnel** pour le pilotage Marketing.
- **Pipeline de données complet et reproductible** via 3 notebooks Jupyter documentés.

8.2 Difficultés Rencontrées

Difficultés Techniques

- Le déséquilibre de classes (73,5 %/26,5 %) représentait un risque majeur de biais du modèle vers la classe majoritaire.
- L'overfitting du modèle XGBoost (AUC-ROC CV 0,9111 vs test 0,7918) a nécessité une seconde itération de GridSearchCV avec régularisation.
- La multicollinéarité entre mois_abonnement et montant_total (corrélation 0,83) a nécessité une analyse approfondie.
- Les trois modèles présentaient des performances très proches sur le jeu de test, rendant la sélection finale non triviale.

Difficultés Métier

- L'adaptation d'un dataset télécom à un contexte streaming a introduit un biais d'interprétation potentiel.
- L'absence de données comportementales réelles (nombre de vues, genres préférés) a limité le pouvoir prédictif du modèle.
- La définition du seuil de décision optimal a représenté un arbitrage métier délicat entre minimiser les faux négatifs et les faux positifs.
- La validation de la cohérence métier des prédictions sans accès à de vrais experts du domaine streaming a constitué une limitation.

8.3 Apports du Projet

Sur le plan technique, le projet a permis de construire un pipeline complet et reproductible allant de la donnée brute jusqu'à la prédiction, en passant par l'exploration, le nettoyage, la modélisation et l'évaluation. Trois modèles de classification ont été comparés de manière rigoureuse, aboutissant à un modèle XGBoost atteignant un AUC-ROC de 0,8177, dépassant l'objectif fixé.

Sur le plan métier, le projet va au-delà de la simple prédiction binaire demandée. L'ajout d'un score de probabilité continu et d'une segmentation en trois niveaux de risque permet à l'équipe Marketing de prioriser ses actions de rétention selon les ressources disponibles. Les 283 clients à risque élevé constituent une liste d'action immédiate, évitant de traiter indistinctement l'ensemble des clients prédits comme churners.

8.4 Perspectives d'Amélioration

- **Enrichissement des données :** intégrer des variables comportementales réelles (nombre de vues par semaine, genres préférés, fréquence de connexion) pour améliorer significativement le pouvoir prédictif du modèle.
- **Automatisation du pipeline :** mettre en place un réentraînement automatique mensuel pour maintenir les performances du modèle face à l'évolution des comportements clients.

- **Intégration CRM :** développer une API REST permettant d'intégrer les prédictions en temps réel directement dans les outils CRM de l'équipe Marketing.
- **Mesure du ROI :** mettre en place un A/B testing des actions de rétention pour quantifier l'impact réel du modèle sur la réduction du churn et justifier l'investissement.